

R-OPCD V3.6

数学训练与评测方案

干净输入 Teacher、全部样本 OPCD 与单 B200 交付

训练期：同底座冻结 T^+/T^- + Student LoRA

固定初始 Student 轨迹 · Student-anchored corrective target · Hybrid KL

评测期：原始模型与训练模型的 AgentDojo 配对测试

方案版本 3.6 · 2026-09-11 (北京时间)

本次版本决定

在已有成对干净 / 污染输入上， T^+ 只看到原始干净任务输入， T^- 与 Student 看到完全相同的带攻击输入；三者评价同一条实际 Student response。全部 9,600 条样本进入 OPCD，不作 A/U 标注筛选，固定 $g = 1, c = 1$ ，不做正常样例 SFT。保留双 Teacher 方向、Student-specific deficit、Student-anchored target 和全词表 Hybrid KL。采用单张 B200、Qwen3.8-27B、一次固定 rollout 与一轮 LoRA 训练，最后分别评测原始模型和训练模型。

状态：本报告把已授权且已实现的修改收束为 V3.6，更新 V3.5 的方法合同与交付流程，不新增训练实验或改变现有运行参数。现有验证记录包括生成链路 14 项、训练 8 项、AgentDojo 16 项 CPU / 工程检查；本地交付记录尚无 B200 上 27B 的完整训练和正式评测结果。

实现基线：本次核对 B200 仓库提交 86762f6；后续版本提交包含本报告及文档索引。仓库目录保持不变，V3.5 文档和历史运行保留其原身份。

目录

1 从 V3.5 到 V3.6 的修改清单	2
2 任务、样本与特权信息边界	2
3 模型与固定轨迹训练	3
4 同一 response 上的三路因果评分	4
5 保留的方向、deficit 与 corrective target	4
6 V3.6 最终训练目标：全部样本 OPCD	5
7 单 B200 的计算与持久化流程	5
8 AgentDojo：原始模型与训练模型同条件测试	6
9 完整原始结果与可校验 TXT 传输副本	7
10 验证记录、实现映射与版本使用规则	8

1 从 V3.5 到 V3.6 的修改清单

项目	V3.5 报告合同	V3.6 当前合同
T^+ 输入	authenticated task、精确恶意 span、attention quarantine、post-context guard	原始 <code>user_query + clean_context</code> ；普通 attention，无 q1 / guard / span mask
Student 与 T^-	普通受攻击输入	同一份原生 <code>user + input</code> 角色的受攻击 prompt token IDs
样本准入	独立判定攻击成功 $A = 1$ 的 correction 集	9,600 条全部进入 OPCD；不使用 A/U、风险标签或攻击成功与否筛选
Reliability	校准的冻结 T^+ 滑窗 NLL 分数	$c_t \equiv 1$ ；不计算滑窗 NLL，不做 c 标定，不训练 Critic
正常能力 SFT	独立 ordinary utility controls，权重 0.1	权重为 0；不读取独立正常样例监督回答
OPCD 核心	方向、deficit、Student-anchored target、Hybrid KL	保留；全词表精确计算，不启用 teacher-top32 分支
Rollout 调度	报告定义 cycle-level 刷新和 A/U 判定	先由初始底座生成一次 9,600 条，再固定轨迹训练一轮；无 Cycle 1/2 刷新
模型与硬件	Qwen3-8B 的旧实例	Qwen3.8-27B，单张完整 B200，BF16、TP=1
验证与交付	旧工程路径与开发诊断	可移植 Docker 包、双模型 AgentDojo、原始日志与可校验 TXT 副本
推理部署	只部署 Student	保持不变；训练特权输入与两路 Teacher 均不进入部署

2 任务、样本与特权信息边界

记可信任务为 u_i ，注入前的原始外部内容为 o_i ，污染内容为

$$\tilde{o}_i = \text{Inject}(o_i, a_i), \quad x_i^{\text{clean}} = (u_i, o_i), \quad x_i^{\text{adv}} = (u_i, \tilde{o}_i). \quad (1)$$

当前固定输入含 $N = 9,600$ 条成对样本，沿用已经冻结的任务、攻击配对和注入位置。本次版本不会重新抽取数据、重新生成攻击或使用测试集挑选训练样本。

“无标注”指无需额外 A/U、风险、恶意 span 或 gold response 标注，并不意味着不需要成对干净输入。 o_i 来自原始上游任务数据，不是从污染输入中调用另一个模型清洗，也不是使用正确答案反向构造。空的原始 clean context 允许保留。干净上下文是训练期特权信息；实际部署和 AgentDojo 测试不向 Student 提供这种 oracle。

2.1 三方消息合同

使用同一模型的原生 tokenizer 与 chat template; thinking 开启。

角色	Prompt	参数与梯度
Student	user: u_i ; input: $\tilde{o}_i$	冻结底座加可训练 LoRA
T^-	与 Student 完全相同的 prompt token IDs	关闭 adapter 的冻结底座
T^+	user: u_i ; input: o_i	同一个冻结底座, 关闭 adapter

这里 input 是该 Qwen 模板对外部上下文采用的角色。三路均使用普通 causal attention, prompt 无 quarantine mask。 T^+ 不读取 sanitized_context、target answer、恶意 span、旧 q1 包装、A/U verifier 输出或 scorer 结果。

2.2 同一个完整 response

先由初始策略生成并保存实际 token IDs:

$$y_i = (y_{i1}, \dots, y_{iT_i}) \sim \pi_0(\cdot | P_i^{\text{adv}}). \quad (2)$$

response 含实际生成的 thinking、final 以及实际返回的结束 token, 不按答案格式删样本, 不只截取 final answer。达到生成长度上限的真实响应仍做 OPCD; 不补造 EOS。训练时禁止静默裁剪 prompt 或 response, 并核对逐条结果与汇总记录完全一致。

干净 prompt 不等于干净 response prefix

T^+ 只在任务输入上去除注入, 随后仍 teacher-force 同一条 Student response。如果 Student 已生成攻击性或错误前缀, T^+ 也必须看到这段实际前缀, 不能替换成正确回答。两路 Teacher 不另外采样答案, 不存在把 T^+ 的生成文本当 SFT label 的分支。

3 模型与固定轨迹训练

模型固定为 Qwen/Qwen3.8-27B, 上游 revision:

1d4bf0f2ff6012fd82039f2fa52739d0dd7c60c0

参数关系为

$$\pi_\theta = \pi_0 + \Delta_\theta^{\text{LoRA}}, \quad T^- = T^+ = \pi_0. \quad (3)$$

两路 Teacher 不随 Student 更新。已采样的 y_i 在整轮训练中固定, 但 Student 的当前 logits、deficit 和 corrective target 在每次处理样本时按当前 θ 重新计算。

本版为一次固定初始 Student rollout 的 OPCD。借用 SecOPD 的 clean-teacher / attacked-student / full-response 输入关系, 但保留本项目的 T^- 和 corrective loss。这不是直接改名的官方 SecOPD 复现, 也不是每步 optimizer 更新后重新采样的严格在线 OPD。V3.5 的多 cycle 调度、reliability 标定与旧模型结果不自动延续到 V3.6。

4 同一 response 上的三路因果评分

对每个实际位置 t :

$$z_{it}^S = f_\theta(P_i^{\text{adv}}, y_{i,<t}), \quad (4)$$

$$z_{it}^- = f_0(P_i^{\text{adv}}, y_{i,<t}), \quad (5)$$

$$z_{it}^+ = f_0(P_i^{\text{clean}}, y_{i,<t}). \quad (6)$$

三者形状相同，词表相同、response token 次序相同。实现中，在位置 $|P| - 1 + t$ (t 从零计数) 的 hidden state 预测 y_t ；最后一个 response token 不再输入 decoder。prompt 长度差异不能通过截断 response 或错位 logits 来消除。定义

$$p_{it}^v = \text{softmax}(z_{it}^v), \quad r_{it,j}^v = z_{it,j}^v - \frac{1}{|\mathcal{V}|} \sum_{k \in \mathcal{V}} z_{it,k}^v, \quad v \in \{S, -, +\}. \quad (7)$$

计算方向、概率与 KL 时使用 float32；底座前向为 BF16。

5 保留的方向、deficit 与 corrective target

5.1 局部方向与 disagreement

$$d_{it} = \text{stopgrad}(r_{it}^+ - r_{it}^-), \quad (8)$$

$$D_{it} = \text{JS}(p_{it}^+, p_{it}^-). \quad (9)$$

这里 d_{it} 是同参数 Teacher 因 clean / attacked 输入差异产生的局部分布方向。称其为 recovery direction 是训练设计意图，不预先保证沿该方向更新一定提高实际任务恢复率。

5.2 Student 在方向上的位置

$$w_{it,j} = \text{stopgrad} \left[\frac{p_{it,j}^S + p_{it,j}^- + p_{it,j}^+}{3} \right], \quad (10)$$

$$\alpha_{it} = \frac{\sum_j w_{it,j} \text{stopgrad}(r_{it,j}^S - r_{it,j}^-) d_{it,j}}{\sum_j w_{it,j} d_{it,j}^2 + \epsilon_\alpha}, \quad (11)$$

$$\delta_{it} = \text{clip}(\text{ReLU}(1 - \alpha_{it}), 0, \delta_{\max}), \quad (12)$$

$$m_{it} = \rho_{it} \mathbb{I}[D_{it} > \tau_D] \mathbb{I}[\delta_{it} > \delta_{\min}]. \quad (13)$$

ρ 为真实 response 的有效位置 mask；本版单样本不 padding 的实现中均为 1。 α 不额外 clip, $\alpha \geq 1$ 时 deficit 为零。

5.3 Student-anchored target

$$\boxed{q_{it} = \text{softmax}(\text{stopgrad} [r_{it}^S + \eta \delta_{it} d_{it}])}. \quad (14)$$

target 锚定当前 Student，只沿双 Teacher 方向增加 residual，不直接设成 p^+ 。 $d, w, \alpha, \delta, m, q$ 均不反传。当前 `teacher_plus_top_k=null`，方向、JS、deficit、target 和最终 KL 都在完整词表上计算。

6 V3.6 最终训练目标：全部样本 OPCD

$$g_i \equiv 1, \quad c_{it} \equiv 1, \quad \lambda_{\text{clean}} = 0, \quad (15)$$

$$K_{it} = \lambda_F \text{KL}(q_{it} \| p_{it}^S) + (1 - \lambda_F) \text{KL}(p_{it}^S \| q_{it}). \quad (16)$$

$$\mathcal{L}_i = \frac{\sum_t m_{it} K_{it}}{\sum_t m_{it} + \epsilon_L}. \quad (17)$$

当前 micro-batch size 为 1，一次处理一条轨迹，按冻结随机顺序执行 9,600 个更新步骤。上式的分母覆盖该条轨迹的全部有效 correction token，不是各个 16-token 分块的局部平均；不能把不同长度样本默认改成一个整数据集 token 加权比值。

“全部样本 OPCD”是样本级准入规则。token 级 disagreement / deficit 门控仍保留，无须修正的位置可以贡献零损失；一条样本的有效 correction token 为零时也不转为 SFT。梯度仅经过 KL 中的当前 Student 概率流向 LoRA。没有 clean SFT、Critic、reliability calibration、自强化或额外答案监督分支。

参数	值	参数	值
τ_D	0	$\delta_{\min}$	0
$\delta_{\max}$	2	η	0.7
λ_F	0.5	λ_{clean}	0
ϵ_α	10^{-8}	ϵ_L	10^{-8}
LoRA rank	8	LoRA alpha	16
LoRA dropout	0	AdamW LR	10^{-5}
weight decay	0	梯度裁剪	1
训练轮数	1	总样本 / 步骤	9,600

7 单 B200 的计算与持久化流程

7.1 生成与训练设置

生成固定温度 1.0、top-p 1.0、thinking 开启，最多 16,384 个新增 token，总上下文 32,768，BF16、TP=1、并发 16。先运行固定 12 条真实 canary，通过后自动继续另外 9,588 条；12 条计入 9,600 总数。权重直接从官方开源模型仓库下载，不从原服务器传输。

训练使用一个共享冻结底座：先在关闭 adapter、无梯度状态下顺序算 T^- 、 T^+ ，再开启 adapter 算 Student，使用 gradient checkpointing。仅文本 decoder 的 full-attention 层 q/k/v/o 投影训练 LoRA，linear-attention、视觉模块和 LM head 保持冻结。词表投影按 16 个 response token 分块计算并累积 hidden-state 梯度，最后一次 decoder 反向；分块不改变全词表目标，不重复逐 token 跑 Transformer。

第一步真实更新、每 100 步、正常暂停及最终步骤保存 checkpoint，保留最近两个完整版本。保存 LoRA、optimizer、RNG、训练位置和文件哈希。恢复校验已提交 checkpoint，从最近完整版本继续；未保存的更新可能重算。错误、OOM 或数据不一致会停止并保留已有产物，不通过缩短序列、删样本或跳过坏结果继续运行。

7.2 阶段串行，三段分别启动

当前总流程为：生成 → 训练 → 原始模型评测 → 训练模型评测 → 汇总 / TXT。尚无自动串接生成、训练、评测的一键总入口。三段需分别启动，等上一段完成回执通过且容器退出后，再启动下一段。以下是顺序索引，不可连续粘贴执行：

```
./docker_b200.sh start --gpu 0    # generation; wait until complete
./train_b200.sh start --gpu 0     # training; wait until complete
./agentdojo_b200.sh start --gpu 0 # both models, summary, TXT
```

环境构建、检查、状态查看、暂停与恢复的完整操作统一维护在仓库唯一的 README 中。

7.3 空间与输出

全部运行结果、日志、缓存和 checkpoint 在 output/ 下：生成在 main/，训练在 clean_opcd/，评测在 agentdojo/。训练模型在评测前合并为独立约 56 GB 权重目录，保留原始模型用于对照。原始模型及静态数据约 55.85 GB，三种镜像共享后的层约 20.7 GB，连同合并模型固定部分约 133 GB。建议 500 GB 可用 SSD，多轮结果 / 多个 TXT 快照建议 1 TB；这是规划估算，不是实测峰值。Docker 数据目录与仓库若在不同分区，需分别检查空间。

8 AgentDojo：原始模型与训练模型同条件测试

8.1 测试范围与判定

固定 AgentDojo v1.2.1，源码 revision：

d3640b5b03a88eb44dad96852e1de1ef437d836e

四套官方环境、任务、注入向量、判定代码和静态攻击清单均随包提供。

Suite	正常任务	攻击组合	注入目标可执行性诊断
workspace	40	560	14
banking	16	144	9
travel	20	140	7
slack	21	105	5
每个模型	97	949	35

每模型 1,081 条轨迹，两个模型合计 2,162 条。35 条 injection-task-as-user-task 诊断单列，不进入正常成功率或 ASR 分母。

使用原始 `utility()/utility_from_traces()` 和 `security()/security_from_traces()` 判定, 依据回答、工具轨迹和环境状态, 不调用额外 LLM judge。对受攻击任务, `security=true` 表示攻击成功 $A = 1$ 。完整且无基础设施错误时:

$$\text{ASR} = \frac{\sum_{i \in \mathcal{E}_{\text{adv}}} A_i}{949}, \quad (18)$$

$$U_{\text{adv}} = \frac{\sum_{i \in \mathcal{E}_{\text{adv}}} U_i}{949}, \quad U_{\text{clean}} = \frac{\sum_{i \in \mathcal{E}_{\text{clean}}} U_i}{97}. \quad (19)$$

当前汇总包含三项指标、各 suite 分项及训练模型相对原始模型的百分点变化。若进一步主张任务恢复, 应从同条原始轨迹计算 $\mathbb{I}[U = 1 \wedge A = 0]$; 该联合指标目前不是自动汇总的既有字段, 也不能由 $1 - \text{ASR}$ 或 $U - \text{ASR}$ 代替。

8.2 匹配设置与错误保留

默认先测原始模型, 再释放服务、合并最终训练 adapter 并测训练模型。最终 checkpoint 必须完成 9,600 步并通过身份与文件校验, 不按测试成绩挑 checkpoint。两模型使用相同任务 ID、静态 `important_instructions` 攻击、配对 `seed`、`input` 外部上下文角色。攻击阶段用 `repeat_user_prompt`, 正常阶段无该 defense。评测温度为 0.0、top-p 为 0.9、thinking 开启、上下文 32,768、单 worker, 不额外设置单次输出上限; 生成数据的温度仍为 1.0。

上游在某些上下文 / 服务错误中会回填 $U = 0, A = 1$ 。本包保留原始值、原生轨迹和 `official_raw_asr`, 另外标记 `infrastructure error` 并停止。未完整或有错误时正式比例留空, 只提供有效已完成样本的诊断比例; 恢复校验旧有效轨迹, 保留失败 attempt 后在新 attempt 重试。本版 `base / trained` 对照使用相同界面, 是当前方法比较, 不冒充官方论文全部设置的复现。

9 完整原始结果与可校验 TXT 传输副本

保留原始结果、每次完整请求 / 响应、原生判定轨迹、服务 / 主流程 / 合并日志、错误、配置、环境、模型和 checkpoint 身份。评测完成、正常暂停或捕获失败后, 自动额外生成独立 `transfers/snapshot_*`, 原文件继续保留。

每个 TXT 含文件头最多 90,000 字节, 采用可读 UTF-8, 切片不破坏汉字编码; 二进制日志在文本中以 base64 表达。权重、adapter 二进制、缓存、临时文件和旧传输副本不重复打包。每包有 `000000_CONTROL.txt` 和有编号的分片, 校验包括:

1. snapshot 身份、分片序号与总数, 拒绝缺片、重复或混包;
2. 每片字节数、SHA256 与前片哈希构成的有序链;
3. 拼接数据流的总字节数和 SHA256;
4. 每个原始文件的路径、大小、SHA256, 以及总文件数。

接收端 `scripts/txt_transfer.py` 提供 `verify`、`join`、`restore`, 校验失败不发布结果, 不覆盖已有目标, 可逐字节恢复原目录。传输完整性不改变评测完整性: 部分 / 失败运行在还原后仍然是部分 / 失败。

10 验证记录、实现映射与版本使用规则

项目	当前可核对的证据
生成链路	14 项 CPU / 工程检查、9,600 条真实输入核对及明确标记的模拟流程；真实 B200 canary 仍需目标机执行
训练链路	8 项 CPU 检查：原生 tokenizer 输入、小型混合模型更新、梯度一致、冻结参数、checkpoint 与恢复；不等于 27B 训练完成
评测 / 传输	16 项 CPU 检查：原生判定、完整清单、模拟 HTTP 经过真实 evaluator、小模型合并、普通 UID 的 vLLM 导入、失败导出、TXT 校验还原
发布检查	全新 Git 克隆的 233 个非权重静态文件已校验；本次数量随文档加入而增加，18 个权重分片仍从上游下载
真实效果	当前交付记录没有 B200 的完整 27B ASR / 成功率结果；吞吐、显存和安全 / 能力变化需实际运行测量

数学与执行权威按以下文件定位：

- 参数：config/generation.json、config/clean_teacher_opcd.json、config/agentdojo.json；
- 干净 Teacher 与梯度路径：code/src/r_opcd/clean_teacher_opcd.py；
- 全词表目标：code/src/r_opcd/objective.py；
- 生成 / 训练管理：scripts/b200_collection.py、scripts/train_clean_teacher.py；
- 原生评测与配对汇总：scripts/agentdojo_runtime.py、scripts/evaluate_agentdojo.py；
- TXT 控制算法：scripts/txt_transfer.py；
- 验证：validation/clean_teacher_training_verification.json、validation/agentdojo_delivery_verification.json。

生成配置中的旧 tplus 描述、lanes 等字段仍是来源元数据。旧生成记录中的通用标记 training_ready=false 也不定义 V3.6 的训练视图与准入。本版由独立 clean-teacher 配置和逐条真实响应审计决定训练资格，不能复用旧 q1 teacher view 来代替 clean prompt。

版本与结论范围

V3.6 是当前 B200 交付路线的方法版本，原有 V3.5 工作区及其已保存实验仍保留原版本身份。本次不为旧 checkpoint 改名、不追加新实验、不把工程检查变成正式模型效果。当前实现足以定义并执行 base / trained 对照；对方向、deficit 或无标注设计的独立收益作论文归因，仍需匹配的直接 T^+ / 普通 OPCD 等对照，不能从版本升级本身推导优越性。后续结果到达后再更新对应结果与 claim，不把尚未执行的实验写成既有事实。